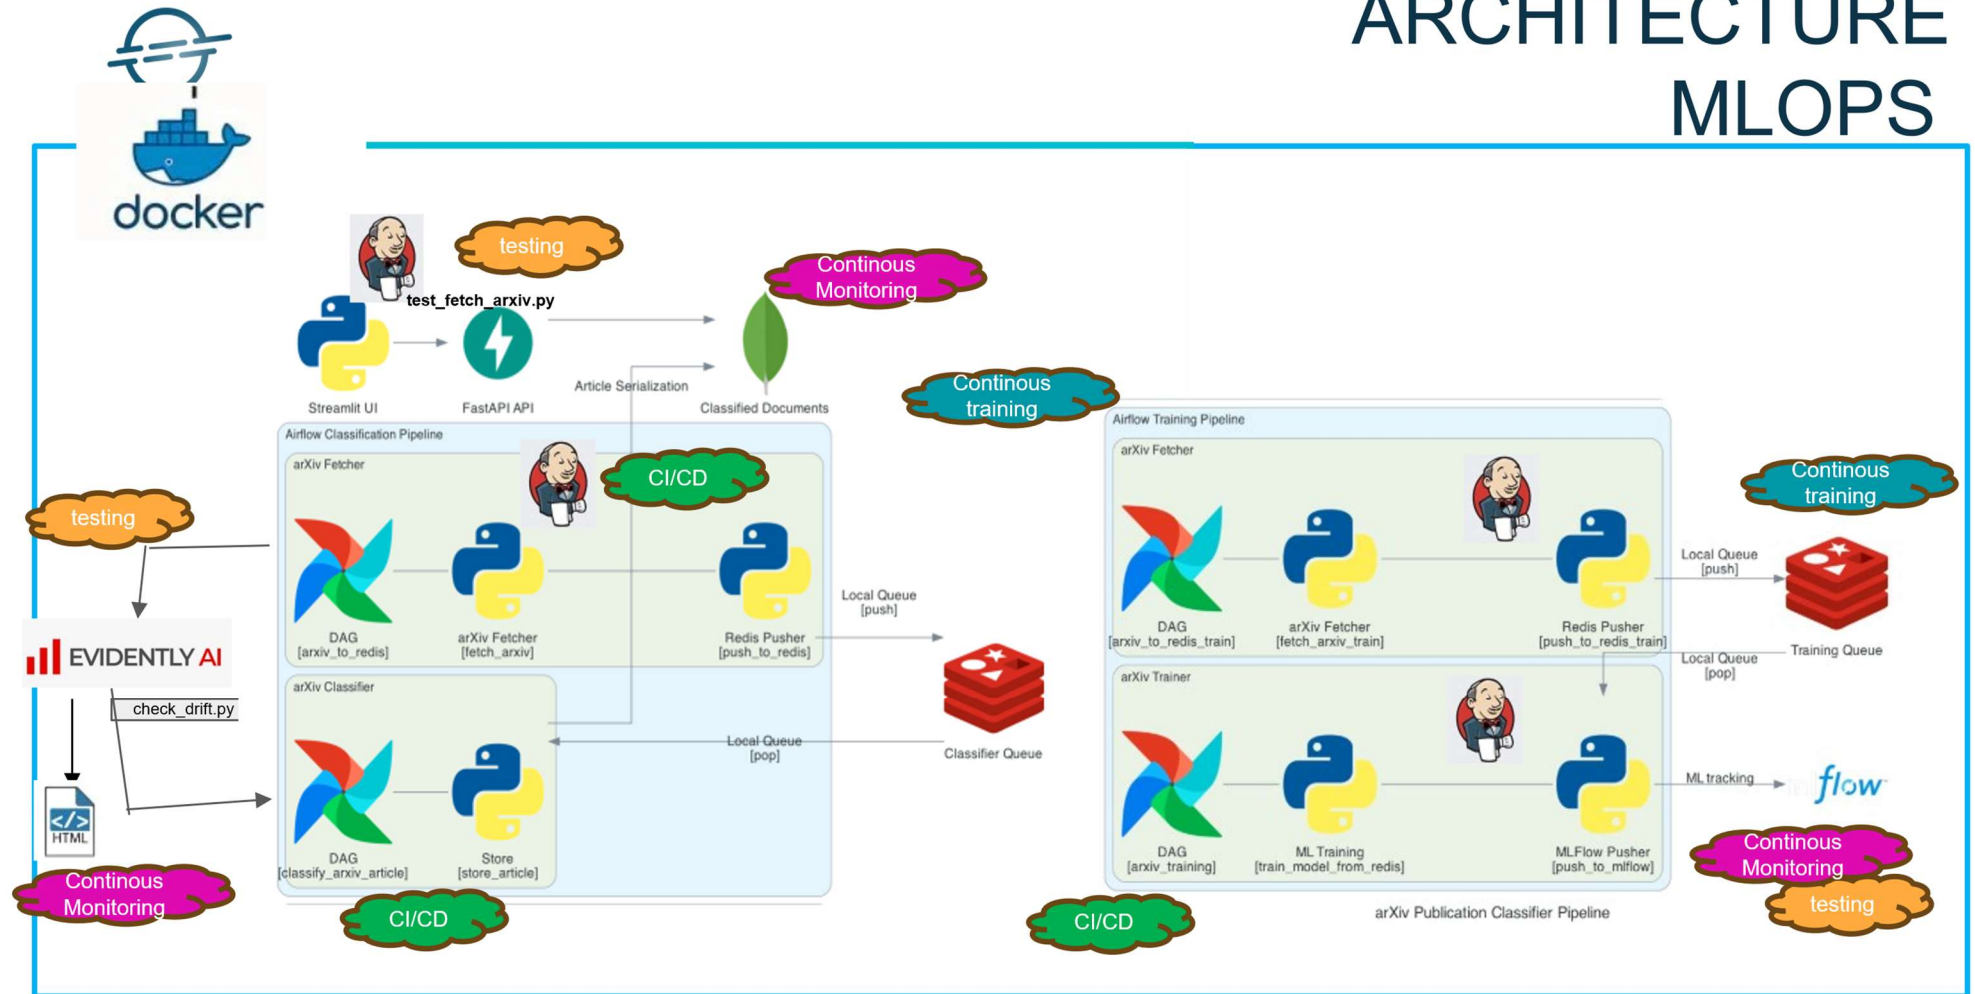


ARCHITECTURE MLOPS



Une architecture développée selon 5 axes

1. Choix d'une double orchestration :

- **Airflow** pour orchestration et répartition du traitement global et lien avec MLOps :
 - o gestion des **dépendances complexes** (arxiv_training ne se lance que si Redis a des données),
 - o des **longues exécutions** (entraînement, *embedding*)
 - o de la **gestion des états** des pipelines ML (CT et CM).
- **Jenkins** : CI/CD de l'Infrastructure par **vérification de qualité des données** précoce via l'exécution des tests unitaires
 - o sur le code d'extraction
 - o l'upload vers S3

2. Surveillance Proactive avec Evidently :

- **Génération** des rapports HTML explicites et des alertes binaires (drift/no-drift), ce qui boucle la boucle du Continuous Monitoring vers un potentiel Continuous Training.

3. Tracabilité via MLFLOW : afin que le modele puisse être reproduit et tracé grâce aux artefacts

- Log des métriques de performance (accuracy) et les hyperparamètres (Tracking).
- Stock des artefacts critiques, y compris le modèle, le LabelEncoder et de manière cruciale pour le monitoring, le fichier de données de référence Evidently (reference_data.csv).
- L'utilisation de la variable LATEST_TRAINING_RUN_ID garantit que le pipeline de monitoring et d'inférence charge toujours le bon modèle et les bonnes données de référence de manière automatique.

4. Découplage et scalabilité : 2 bases de données distinctes

- **MongoDB (Feature/Data Store)** : Choisi pour stocker des documents JSON (non structurés) contenant des informations complexes comme les **Embeddings** (vecteurs de caractéristiques) et les prédictions.
- **Redis (Message Queue)** : utilisé pour le découplage asynchrone (Data Buffer), la collecte de données rapide, tandis que le traitement lourd (embedding/classification) peut consommer à son propre rythme.
→ Cela gère les pics de charge et augmente la robustesse du pipeline.

5. Reproductibilité de l'Environnement (Docker)

- Ensemble de **l'environnement containerisé** (développement, testing, production)
- Pour une **indépendance** des différents services, et de chaque étape MLOPS
- Garant d'une **reproductibilité** des modèles et des tests